

발표자: 김영민, 이다인

Image generator : 김영민, 김지수, 이다인

# INDEX

**001 Introduction**

**002 Deep Residual Learning**

**003 Experiments**

(0) Network Architectures

(1) ImageNet Classification

- Plain vs ResNet

- Identity vs projection

- Deeper layer with Bottleneck Architecture

(2) CIFAR-10


(3) Object detection & Segmentation task

# 1. Introduction


## Question

많은 층으로 구성되어 있는 네트워크가 항상 좋은 성능을 낼까?


**NO!!!**



Train error rate



Test error rate



Train & Test 셋  
둘 다 층이 깊어질수록

에러율



# 1. Introduction


Overfitting

Train 성능 ↑ Test 성능 ↓

Degradation

Train 성능 ↓ Test 성능 ↓

What is Solution? → **Residual Learning**



Residual Block

	Optimization
Original Mapping	<b>Hard</b>
Residual Mapping	<b>Easy</b>

## 2. Deep Residual Learning

Plain Layers

$$H(x) = F(x) + x$$


Residual Layers

$$F(x) = H(x) - x$$

$H(x)$ : Original mapping

$F(x)$ : Residual

$x$ : Input



여러 비선형 Layer들이 복잡한 함수하고  
Identity mapping이 최적이라면

$H(x)$ 를 mapping 시키는 것 보다  
잔차인  $F(x)=0$ 으로 만드는 것이 더 쉽다

## 2. Deep Residual Learning

Shortcut connection

한 개 이상의 layer를 skip 하는 것

**조건 !!**

Input layer dimension == output layer dimension

1. If input.ndim == output.ndim

$$\mathcal{F} = W_2 \sigma(W_1 \mathbf{x})$$




$$\mathbf{y} = \mathcal{F}(\mathbf{x}, \{W_i\}) + \mathbf{x}.$$

$\mathbf{x}$ : Input

$\mathbf{y}$ : Output vector

$W$ : weight layer

Identity shortcut



2. If input.ndim != output.ndim

$$\mathbf{y} = \mathcal{F}(\mathbf{x}, \{W_i\}) + W_s \mathbf{x}.$$

$\mathbf{x}$ : Input

$\mathbf{y}$ : Output vector


$W$ : weight layer

$W_s \mathbf{x}$ : Square matrix

Projection shortcut

# 3. Experiments

## (0) Network Architectures : 34-layers plain vs 34- layers ResNet

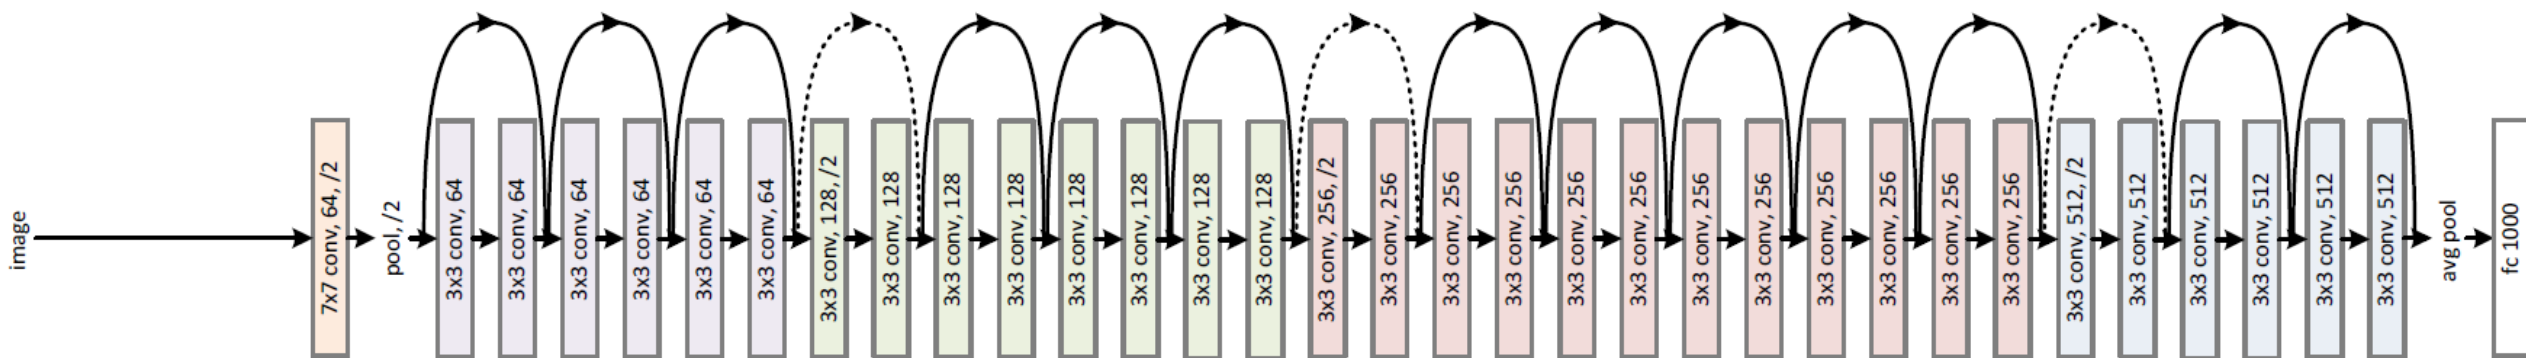


### 34-layers Plain network

- 기본 네트워크는 VGG 네트워크에서 제안된 기법들을 적절히 이용
- 3x3의 작은 filter 이용, output feature map size에 같도록 하기 위해 같은 개수의 filter 사용
- feature map의 사이즈가 절반으로 줄어든 때는 filter의 개수를 2배로 늘려서( 다음 layer의 channel 값을 2배로 늘림) 이런 방법으로 layer마다 time-complexity를 보존하는 형태로 구성
- 별도의 pooling layer 사용 X, convolution layer에서 stride 값을 2로 설정해 downsampling 진행
- layer의 마지막 부분에서 average pooling을 사용해 1000개의 클래스로 분류할 수 있도록 함
- 본 모델은 일반적인 VGG 네트워크와 비교했을 때 더 적은 파라미터 사용, 복잡도가 낮음

# 3. Experiments

## (0) Network Architectures : 34-layers plain vs 34-layers ResNet



### 34-layers ResNet

- convolution filter를 두개씩 묶어서 매번 residual function 형태로 학습을 진행함
- 점선으로 표시된 것은 입력단과 출력단의 dimension이 일치하지 않아 dimension을 맞춰줄 수 있는 테크닉이 가미된 shortcut connection
- convolution layer를 두개씩 묶는 것을 총 3번반복, 그 다음 크기를 바꾸고 4번 반복, 또 다시 크기를 바꾸고 6번 반복, 크기 바꾸고 3번 반복하는 식으로 구성됨
- VGG와 비교 했을 때 FLOPs(계산 복잡도를 나타내는 척도)가 감소



# 3. Experiments

## (1) ImageNet




Num of Class	Num of Training images	Num of Validation images	Num of Test images
1,000	1,280,000	50,000	100,000

ImageNet Classification에서는 3가지 포인트에 대해 실험 진행


- 1 ) Comparing Plain network and ResNet
- 2 ) Identity and projection shortcut impacts on the performance
- 3 ) Comparing 34, 50, 101 and 152 layer ResNet

# 3. Experiments

## (1)-1 ImageNet Classification : Comparing Plain network and ResNet



Plain network



ResNet

	plain	ResNet
18 layers	27.94	27.88
34 layers	28.54	<b>25.03</b>

### 3. Experiments


#### (1)-2 Identity and projection shortcut impacts on the performance

model	top-1 err.	top-5 err.
VGG-16 [41]	28.07	9.33
GoogLeNet [44]	-	9.15
PReLU-net [13]	24.27	7.38
plain-34	28.54	10.02
ResNet-34 A	25.03	7.76
ResNet-34 B	24.52	7.46
ResNet-34 C	<u>24.19</u>	<u>7.40</u>
ResNet-50	22.85	6.71
ResNet-101	21.75	6.05
ResNet-152	<b>21.43</b>	<b>5.71</b>

A : zero – padding을 사용해 dimension을 늘려주고 identity mapping 사용

B : dimension이 증가할 때만 projection 연산 수행

C : 모든 연산에 대해서 projection 수행




ResNet-C가 가장 좋은 결과를 보여주지만 그 차이가 미세하고 memory/ time complexity가 늘어나기 때문에 효율적이지 X

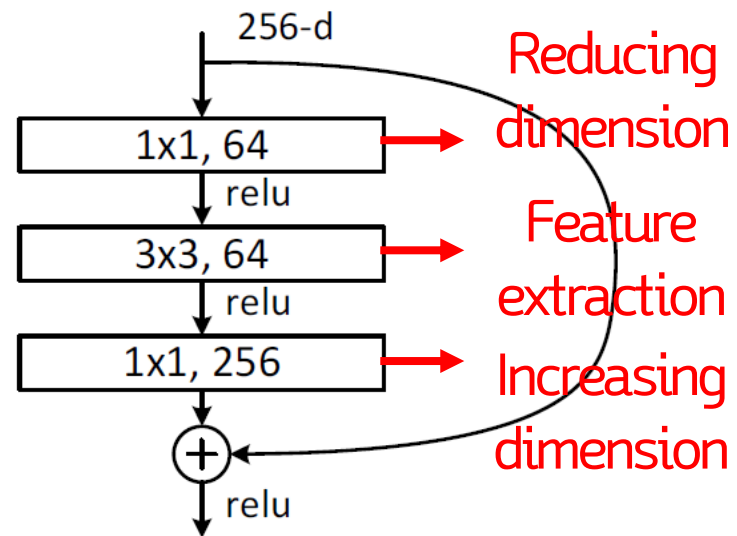
# 3. Experiments

## (1)-3 Comparing 34, 50, 101 and 152 layer ResNet with Bottleneck Architecture

Not Bottleneck



Bottleneck




Deeper Bottleneck result

method	top-1 err.	top-5 err.
VGG [41] (ILSVRC' 14)	-	8.43 <sup>†</sup>
GoogLeNet [44] (ILSVRC' 14)	-	7.89
VGG [41] (v5)	24.4	7.1
PReLU-net [13]	21.59	5.71
BN-inception [16]	21.99	5.81
ResNet-34 B	21.84	5.71
ResNet-34 C	21.53	5.60
ResNet-50	20.74	5.25
ResNet-101	19.87	4.60
ResNet-152	<b>19.38</b>	<b>4.49</b>

# 3. Experiments

## (2) CIFAR-10




Num of Class	Num of Training images	SIZE OF IMAGE	Num of Test images
10	50,000	32x32	10,000


CIFAR-10 Classification은 보다 훨씬 더 깊은 네트워크에서 ResNet이 error-rate를 줄여줄 수 있는지 확인하기 위해 실험 진행

# 3. Experiments


## (2) CIFAR-10



Plain Network



ResNet



ResNet 110 vs 1202

## 3. Experiments

### (3) Object detection & Segmentation task

training data	07+12	07++12
test data	VOC 07 test	VOC 12 test
VGG-16	73.2	70.4
ResNet-101	<b>76.4</b>	<b>73.8</b>

[PASCAL]

metric	mAP@.5	mAP@[.5, .95]
VGG-16	41.5	21.2
ResNet-101	<b>48.4</b>	<b>27.2</b>

[MS COCO]

-> mAP(%)값을 비교한 결과 기존 VGG 네트워크에 비해 더욱 좋은 성능을 보임

감사합니다 ^^