


U-Net: Convolutional Networks for Biomedical Image Segmentation



Contents

Introduction


Third

Fourth

Fifth

Introduction

U-Net: Convolutional Networks for <u>Biomedical Image</u> Segmentation



Biomedical task

- Output이 classification뿐만 아닌 위치 정보를 포함해야함
 대부분의 상황에서 training image의 수가 적음
 같은 class 객체들이 접촉하여 있는 경우가 많음


Patch: 이미지 인식 단위

이 논문에선 sliding window처럼 이미지를 잘라 인식하는 단위 를 만들었는데, 이것이 Patch입니다. 파란색, 노란색 박스 부분 입니다.

Context: 이웃한 픽셀들 간의 관계. 글을 읽고 문맥을 파악하듯 이미지 일부를 보고 이미지의 문맥을 파악하는 것

Short Summary


• • •




- 1. 'U'모양의 End-To-End 구조
- 2. 넓은 범위의 이미지 픽셀로부터 의미정보(Context Information)를 추출하고 의미정보를 기반으로 각 픽셀마다 객체를 분류
- 3. 서로 근접한 객체 경계를 잘 구분하도록 학습하기 위하여 Weighted Loss를 제시

U-net Architecture


• • •





채널 방향에서 바라봄

U-net Architecture




U-Net Architecture

 $Input(Width \times Height \times RGB) -> Model -> Output(Width \times Height \times Class)$

Contracting Path(수축경로)
- 이미지 feature map에서 context를 추출

Expanding Path(확장경로) - Upsampling을 통해 정확한 localization


Contracting Path



Contracting Path(수축경로)
- 이미지 feature map에서 context를 추출

Down sampling 과정을 반복하면서 feature map을 생성


Expading Path



Expanding Path(확장경로) : 정확한 localization을 위한 단계


Up-sampling의 최대 단점: feature map 정보 소실

해결: 이전 layer의 정보를 concatenate



Training - Overlap tile strategy


• • •




Training - Mirroring Extrapolatation

• • •








Mirroring extrapolatation



Training - Data Augmentation








esulting deformed image for visualization: no rotation, no shift, no extrapolation)

적은 데이터로 충분한 학습을 하기위해 data augmention 사용 Elastic Deformation : 세포 조직의 실질적인 변형과 유사

Training - Weight Loss



$$w(\mathbf{x}) = w_c(\mathbf{x}) + w_0 \cdot \exp\left(-\frac{(d_1(\mathbf{x}) + d_2(\mathbf{x}))^2}{2\sigma^2}\right)$$
$$p_k(\mathbf{x}) = \exp(a_k(\mathbf{x})) / \left(\sum_{k'=1}^K \exp(a_{k'}(\mathbf{x}))\right)$$
$$E = \sum_{\mathbf{x} \in \Omega} w(\mathbf{x}) \log(p_{\ell(\mathbf{x})}(\mathbf{x}))$$

 $d_{\mathsf{1}}(x)$: 픽셀 x로부터 가장 가까운 셀 경계까지의 거리

 $d_2(x)$: 픽셀 x에서 두 번째로 셀 경계까지의 거리

W(x) : 픽셀 x와 경계의 거리가 가까우면 큰 값을 갖게 됨
 → 해당 픽셀의 Loss 비중이 커짐

Training

• • •




Fig. 3. HeLa cells on glass recorded with DIC (differential interference contrast) microscopy. (a) raw image. (b) overlay with ground truth segmentation. Different colors indicate different instances of the HeLa cells. (c) generated segmentation mask (white: foreground, black: background). (d) map with a pixel-wise loss weight to force the network to learn the border pixels.

$$p_k(\mathbf{x}) = \exp(a_k(\mathbf{x})) / \left(\sum_{k'=1}^K \exp(a_{k'}(\mathbf{x})) \right)$$
$$E = \sum_{\mathbf{x} \in \Omega} w(\mathbf{x}) \log(p_{\ell(\mathbf{x})}(\mathbf{x}))$$


 $a_k(x)$: 픽셀imes가 Class k일 값 (픽셀 별 모델의 output)

 $p_k(x)$: 픽셀 x가 Class k일 확률(0 -1)

 $l(\pmb{x})$: 픽셀 imes의 실제 Label

U-Net의 개선점

• • •




2. Context인식과 localization의 trade-off 해결

Experiments

• • •

1. EM segmentation challenge(2015), 현미경 이미지




EM 이미지의 일부 어려운 부분


Rank	Group name	Warping Error	Rand Error	Pixel Error
	** human values **	0.000005	0.0021	0.0010
1.	u-net	0.000353	0.0382	0.0611
2.	DIVE-SCI	0.000355	0.0305	0.0584
3.	IDSIA [1]	0.000420	0.0504	0.0613
4.	DIVE	0.000430	0.0545	0.0582
:				
10.	IDSIA-SCI	0.000653	0.0189	0.1027

Warping Error : 객체 분할 및 병합이 잘 되었는지에 대한 segmentation error

2. ISBI cell tracking challenge




92% IOU Score



77.5% IOU Score

Conclusion





U-Net은 Fully Connected Networds보다 확장된 개념의 Up-sampling과 Skip Architecture를 적용한 모델을 제안했다.

결과적으로 U-Net의 구조는 아주 적은 양의 학습 데이터만으로 Data Agmentation을 화룡 하여 많은 training image를 필요로하지 않는다 여러 Biomedical Image Segmentation문제에서 우수한 성능을 보여주었습니다.

Contracting path에서 포착한 피쳐맵의 컨텍스트와 결합하여 더 정확한 로컬라이제이 션을 한다.

참고한 사이트 및 이미지 출처

https://joungheekim.github.io/2020/09/28/paper-review/

https://medium.com/@msmapark2/u-net-%EB%85%BC%EB%AC%B8-%EB%A6%AC%EB%B7%B0-u-net-convolutional-networks-for-biomedicalimage-segmentation-456d6901b28a

https://mylifemystudy.tistory.com/87

https://velog.io/@goe87088/%EB%85%BC%EB%AC%B8-U-Net-Convolutional-Networks-for-Biomedical-Image-Seamentation

https://m.blog.naver.com/9709193/221979612209

https://everyday-image-processing.tistory.com/58

https://medium.com/@codecompose/u-net-174d1bc7627c

http://www.affineanalytics.com/blog/data-augmentation-for-deep-learning-algorithms/

감사합니다